Actividad Módulo 2

Proyecto de análisis predictivo y modelado de datos en el deporte.

Actividad

El objetivo de esta actividad es que se realice un análisis predictivo basado en un conjunto de datos ficticios. Deberás simular un caso deportivo en el que se recojan y manipulen datos, realizarás el análisis de los mismos y crearás un modelo predictivo. Posteriormente, evaluarás los resultados del modelo y presentarás recomendaciones estratégicas a partir de sus conclusiones.

A resolver

Competencias de la actividad y rúbrica de evaluación

Competencia	Calificación
CA01: Generar datos ficticios de manera coherente.	
CA02: Realizar la exploración y limpieza de los datos.	
CA03: Aplicar un modelo predictivo.	
CA04: Evaluar el modelo predictivo.	
CA05: Redactar un informe técnico con recomendaciones.	

Tabla de contenido

1. *Generación de datos ficticios.* 3
2. *Exploración y limpieza de datos* 3
3. *Modelo predictivo y Evaluación del Modelo* 6
4. *Informe final* 10

1. Generación de datos ficticios.

Github: https://github.com/rodrigobg1304/Master_Modulo_2

Se ha generado un fichero ficticio con una herramienta de IA incluyendo resultados de partidos de fútbol generados de manera aleatoria pero que sean consistentes con la realidad, el dataset contiene **760 partidos ficticios** de la primera división española "La Liga" correspondientes a **dos temporadas completas** (2023/24 y 2024/25).

He diseñado la estructura de este dataset tras chequear varias páginas de eventos deportivos como Sofascore (1) recopilando las estadísticas globales más importantes de cada equipo, en el siguiente apartado se explicará cada una de ellas.

En la carpeta de Input, encontrarás 2 datasets:

- **football_matches_dataset.csv**: Dataset original donde hay datos faltantes.
- **football_matches_dataset_clean.csv**: Dataset limpio tras EDA y limpieza de datos.

2. Exploración y limpieza de datos

Características del dataset:

- **Total de registros:** 760 partidos
- **Temporadas:** 2 (2023/24 y 2024/25)
- **Equipos:** 20 equipos de La Liga
- **Jornadas por temporada:** 38 (todos contra todos, ida y vuelta)
- **Total de columnas:** 44 features, separadas por equipo local y visitante, a excepción de columnas comunes:
    - **Información general:** temporada, jornada, fecha, hora, equipo (local y visitante).
    - **Goles:** goles, xG (Goles esperados).
    - **Tiros:** tiros, tiros_puerta.
    - **Disciplina:** faltas, amarillas, rojas.
    - **Balón parado:** corners.
    - **Acciones defensivas:** despejes, intercepciones, paradas_portero, duelos_aereos, duelos_terrestres.
    - **Acciones ofensivas:** pases, precision_pases, posesion, regates, perdidas, fueras_juego.

Durante el **Análisis Exploratorio de Datos (EDA)** correspondiente al apartado 2.1. EDA del notebook, se ha procedido a realizar un análisis descriptivo del dataset original en el que se observa lo siguiente:

De las 44 columnas creadas, 14 de ellas se encuentran valores nulos distribuidos en las siguientes columnas. Corresponde a un 1,57% del total de datos que tenemos, sin embargo, esto hay que tratarlo para realizar predicciones acertadas.

```
======================================================================
ANÁLISIS DE VALORES NULOS
======================================================================

Total de columnas: 44
Total de columnas con valores nulos: 14
Porcentaje total de nulos en el dataset: 1.57%

Total de filas en el dataset: 760

                            Valores_Nulos  Porcentaje
xg_local                               60        7.89
xg_visitante                           60        7.89
intercepciones_local                   53        6.97
intercepciones_visitante               53        6.97
duelos_aereos_local                    45        5.92
duelos_aereos_visitante                45        5.92
precision_pases_local                  38        5.00
precision_pases_visitante              38        5.00
regates_local                          30        3.95
regates_visitante                      30        3.95
tiros_puerta_local                     22        2.89
tiros_puerta_visitante                 22        2.89
paradas_portero_local                  15        1.97
paradas_portero_visitante              15        1.97
```

Ilustración 1- Distribución de valores nulos

Para realizar la limpieza de datos de estas columnas se han seguido diferentes técnicas ya que todas ellas no deberían rellenarse con la media global, podría distorsionar la realidad. Como se explica en el notebook también se ha realizado de la siguiente forma:

- **Tiros a puerta**: Utilizaremos una relación de proporción, ya que alrededor de un 35-40% de los disparos van a puerta, analizar por equipo.
- **xG**: Se utiliza el algoritmo KNN (K-Nearest Neighbors o K-vecinos más cercanos) los xG están altamente correlacionado con goles, tiros y tiros a puerta.
- **Intercepciones y Duelos**: Mediana global, existe menos variabilidad entre equipos
- **Precisión de pases, Regates, Paradas del Portero**: Mediana por equipo:
    - Cada equipo tiene su propio estilo y nivel
    - Los equipos técnicos regatean más que equipos físicos
    - Calidad del portero varía por equipo

Tras realizar este tratamiento de datos, el dataset (**football_matches_dataset_clean**) está listo para usarse.

```
======================================================================
ANÁLISIS DE VALORES NULOS DESPUÉS DE LA LIMPIEZA
======================================================================

Total de columnas: 44
Total de columnas con valores nulos: 0
Porcentaje total de nulos en el dataset: 0.0%

Total de filas en el dataset: 760
```

Ilustración 2 - Dataset limpio

Una vez limpios todos los datos, se procede a revisar si existen algún tipo de outliers, sacando los 10 más representativos observamos lo siguiente:

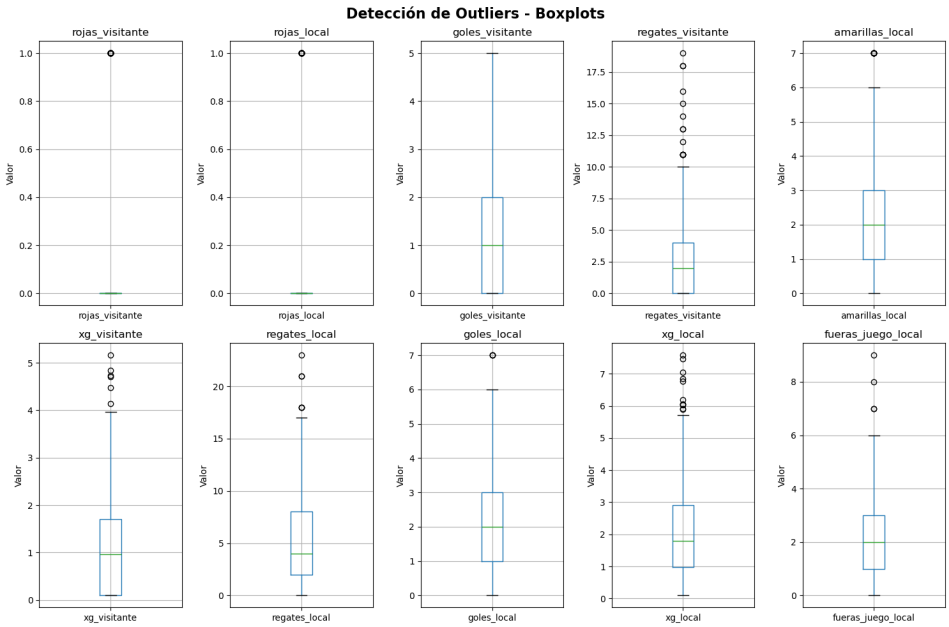

Ilustración 3 - Top 10 outliers

En este caso, no es necesario eliminar ninguno de ellos ya que son eventos deportivos válidos. Los eventos excepcionales ocurren en el fútbol, puede haber partidos con goleadas (+4 goles), tarjetas rojas son eventos que ocurren en algunos partidos, regates, fueras de juego… Los modelos predictivos deben capturar y aprender de estos casos extremos.

Por último, para finalizar con el EDA se ha creado una matriz de correlación para ver que variables están más relacionadas entre sí, se han elegido las features más clave para ver el resultado de un partido.

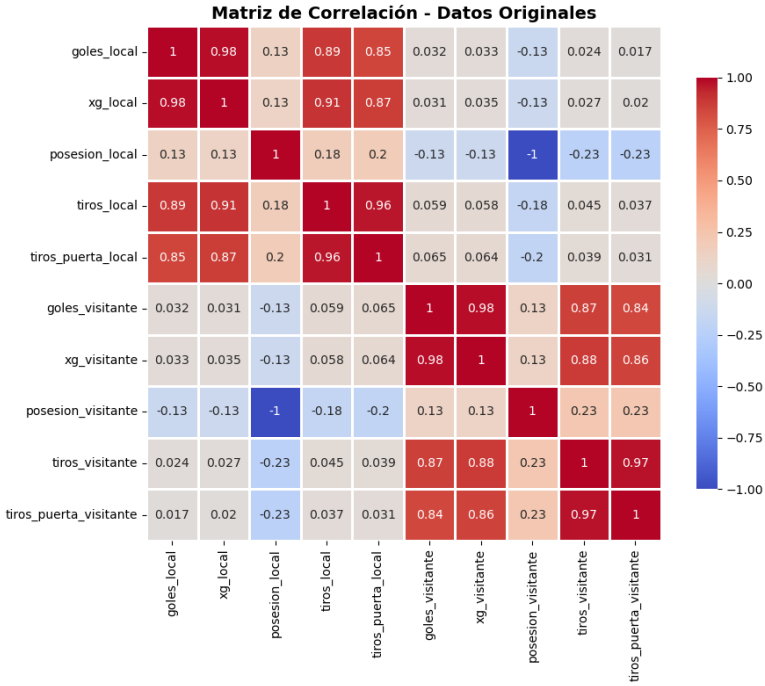

Ilustración 4 - Matriz de correlación

3. Modelo predictivo y Evaluación del Modelo

Para realizar el modelo predictivo se han realizado 4 modelos distintos, todos ellos son supervisados:

3.1. Regresión lineal

El **objetivo** de este modelo es ser capaz de predecir los puntos que puede realizar un equipo por temporada. Al ser una variable numérica, es el algoritmo que se debe utilizar.
Calculamos la variable real `puntos_totales` a partir de los goles del equipo local y visitante ya que no viene por defecto en el dataset original. Nuestra **variable objetivo** será predecir esta feature, para ello es importante seleccionar las features adecuadas para entrenar el modelo. En nuestro caso obviamos las columnas de goles y xG ya que el modelo entiende que estas columnas son las responsables de nuestra variable objetivo, produciendo un target leakage (fuga del objetivo)

```
features = [
    'avg_tiros_puerta',
    'avg_precision_pases',
    'avg_posesion',
    'avg_corners',
    'avg_duelos_terrestres',
    'avg_paradas_portero'
]

target = 'puntos_totales'
```

Una vez seleccionadas las features y la variable objetivo, debemos separar el conjunto de datos en Train/Test (80%-20%)

```
Train/Test Split...
--------------------------------------------------------------------------------
Distribución del split:
        Train: 32 registros (80.0%)
        Test:  8 registros (20.0%)

Estadísticas de puntos:
        Train - Media: 52.97, Min: 36, Max: 69
        Test  - Media: 51.00, Min: 36, Max: 57
```

Ilustración 5 - Regresión Lineal

Como se puede observar, el muestreo es muy pequeño lo que producirá una mala predicción, serían necesarias más temporadas.
Una vez entrenado el modelo, podemos observar la distribución de los coeficientes en el modelo.

Feature	Coeficiente
avg_tiros_puerta	9.367327
avg_paradas_portero	-5.786060
avg_corners	2.390773
avg_duelos_terrestres	0.541881
avg_precision_pases	-0.538360
avg_posesion	0.325320

Evaluando el modelo, podemos sacar conclusiones interesantes que previamente se habían presupuesto.

```
Evaluando el modelo...
------------------------------------------------------------
📊 MÉTRICAS EN TRAIN:
        R² Score:  0.7482
        RMSE:      4.52 puntos
        MAE:       3.52 puntos

📊 MÉTRICAS EN TEST:
        R² Score:  0.4353
        RMSE:      5.38 puntos
        MAE:       4.66 puntos

Interpretación:
   • R² = 0.4353: El modelo explica 43.53% de la varianza
   • MAE = 4.66: Error promedio de ±4.66 puntos por temporada
   • RMSE = 5.38: Penaliza errores grandes más fuertemente

Posible overfitting (diferencia R²: 0.3129)
```

Ilustración 6 - Evaluación Regresión Lineal

Los resultados indican que la regresión lineal explica el 43,53% de la varianza de los puntos por temporada en test (**R²**=0.435). Existe un overfitting considerable, pasando de casi un 75% en entrenamiento a 43% en test, el modelo parece que memoriza los datos de entrenamiento, pero no generaliza. Si analizamos el **MAE** observamos que existe un error promedio de ±4.66 puntos por temporada que obviamente es mayor en **RMSE** al penalizar más los errores. Para conseguir una evaluación más confiable probaremos con una validación cruzada, rotando los datos para intentar mejorar el rendimiento.

3.2. Validación Cruzada con regresión lineal

El **objetivo** de este modelo es mejorar el rendimiento del anterior, la variable objetivo es la misma y las features también, utiizaremos 5 K-Fold para observar el comportamiento. Una vez entrenado el modelo los resultados obtenidos en train/test para cada Fold son los siguientes.

```
🔄 VALIDACIÓN CRUZADA - REGRESIÓN LINEAL
------------------------------------------------------------
Configuración: 5-Fold Cross-Validation
  • Cada fold tendrá ~8 registros de test

Modelo entrenado exitosamente!
📊 Resultados por Fold:

Fold   R² Train     R² Test      MAE        RMSE
-----------------------------------------------------
1      0.7482       0.4353       4.66       5.38
2      0.7052       0.6550       2.90       3.87
3      0.7872       -0.1864      6.20       7.24
4      0.7361       0.4874       4.85       6.45
5      0.6701       0.7229       4.59       5.25
```

Ilustración 7 - CV Regresión lineal

```
Fold   R² Train     R² Test      MAE        RMSE
--------------------------------------------------------
Media  0.7294       0.4228       4.64       5.64
Std    0.0396       0.3223       1.05       1.15

💡 Interpretación:
   • R² promedio: 0.4228 ± 0.3223
   • MAE promedio: 4.64 ± 1.05 puntos
   • Variabilidad entre folds: Alta
   • Diferencia Train-Test: 0.3065
```

Ilustración 8 - CV Regresión lineal media

La desviación estándar del **R²** (std) es similar a su media, indicando una alta inestabilidad en el modelo. Algunos folds, especialmente (2 y 5) alcanzaron un rendimiento aceptable y otros como el fold 3 peor, esto indica que el modelo es muy sensible a la partición. Tanto el **MAE** como el **RMSE** es similar al anterior modelo, por lo tanto, no se ha conseguido una evaluación robusta.

3.3. Regresión logística

Como la regresión lineal probada anteriormente no fue demasiado robusta, decidí comprobar la probabilidad de que sucediese un evento, es este caso el **objetivo** es Over/Under 2.5 goles en el partido. Al crear la variable binaria, observé que las clases estaban bien balanceadas, por lo tanto, podría ser un modelo más robusto. En los partidos registrados un 51% ocurre más de 2.5 goles y en el 49% no.

```
================================================================================
REGRESIÓN LOGÍSTICA - PREDICCIÓN OVER 2.5 GOLES
================================================================================

Creando variable objetivo binaria...
--------------------------------------------------------------------------------

🎯 Distribución de la variable objetivo:
over_2_5
1    388
0    372
Name: count, dtype: int64

Porcentajes:
over_2_5
1    51.052632
0    48.947368
Name: proportion, dtype: float64

Balance de clases: 95.88%
Dataset balanceado
```

Ilustración 9 - Regresión logística objetivo

En este caso, se seleccionaron 18 variables para poder realizar la probabilidad de que ocurriese el evento, para más información revisar el apartado 3.2. Preparar features y variable objetivo del notebook.
Para la distribución train/test seguimos la misma estrategia de 80/20 y normalizamos las features para que estén todas en la misma escala. Por ejemplo, variables como posesión o precisión de pases son mucho mayores a tiros o corners.

```
Train/Test Split...
----------------------------------------------------
Distribución del split:
   Train: 608 partidos (80.0%)
   Test:  152 partidos (20.0%)

Distribución de clases:
   Train - Over 2.5: 310 (51.0%)
   Test  - Over 2.5: 78 (51.3%)
```

Ilustración 10 - Regresión logística

Una vez entrenado el modelo, comprobamos que su evaluación es muy robusta tanto en train como en test.
El **accuracy** es casi perfecto tanto en train como en test.
La **precisión** casi perfecta en train y perfecta en test, verdaderos positivos sobre los positivos predichos.
La **sensibilidad** es casi perfecta, verdaderos positivos sobre los positivos reales.
F1-score es un balance entre precisión y sensibilidad.
El área bajo la curva en **ROC-AUC** indica que el modelo es capaz de discriminar perfectamente entre ambas clases.

```
📈 Evaluación del modelo de regresión logística...
=====================================================

📊 MÉTRICAS EN TRAIN:
   Accuracy:  0.9474 (94.74%)
   Precision: 0.9513
   Recall:    0.9452
   F1-Score:  0.9482
   ROC-AUC:   0.9913

📊 MÉTRICAS EN TEST:
   Accuracy:  0.9737 (97.37%)
   Precision: 1.0000
   Recall:    0.9487
   F1-Score:  0.9737
   ROC-AUC:   0.9932
```

Ilustración 11 - Evaluación Regresión Logística

La matriz de confusión obtenida para el test quedó de la siguiente forma, solo teniendo 4 casos de Falsos negativos, el resto acertó todo.

- True Negatives (TN): 74 - Predijo Under, era Under
- False Positives (FP): 0 - Predijo Over, era Under
- False Negatives (FN): 4 - Predijo Under, era Over
- True Positives (TP): 74 - Predijo Over, era Over

Este modelo es muy robusto y es capaz de tener una exactitud casi en el 100% de los casos.

3.4. Random Forest

Por último, para comparar el modelo anterior con otro, hemos optado por random forest, vamos a comparar los resultados de Over/Under 2.5 goles. Utilizando las mismas features que en regresión logística, lo único que debemos realizar es el entrenamiento. En nuestro caso 100 árboles con una profundidad de 10. Al evaluar el modelo, encontramos similitudes con el de regresión logística.
Vemos que los resultados tanto en train como en test son casi idénticos al anterior, sin embargo, comete algún error en el test respecto a la regresión logística.

```
📈 Evaluando el modelo Random Forest...
======================================================

📊 MÉTRICAS EN TRAIN:
   Accuracy:  0.9967 (99.67%)
   Precision: 0.9968
   Recall:    0.9968
   F1-Score:  0.9968
   ROC-AUC:   0.9999

📊 MÉTRICAS EN TEST:
   Accuracy:  0.9408 (94.08%)
   Precision: 0.9600
   Recall:    0.9231
   F1-Score:  0.9412
   ROC-AUC:   0.9915
```

Ilustración 12 - Evaluación Random Forest

- True Negatives (TN): 71 - Predijo Under, era Under
- False Positives (FP): 3 - Predijo Over, era Under
- False Negatives (FN): 6 - Predijo Under, era Over
- True Positives (TP): 72 - Predijo Over, era Over

En resumen, como el problema de clasificación tiene una naturaleza lineal, no tiene sentido utilizar un Random Forest ya que introduce overfitting sin mejorar el rendimiento (99.67% en train), además captura patrones que no es capaz de generalizar en el test.

4. Informe final

En este apartado se sacarán algunas recomendaciones sobre todo lo expuesto anteriormente, la descripción del dataset, análisis exploratorio, modelo predictivo y evaluación de los distintos modelos ya han sido detalladas.

Como conclusión y a partir de los resultados obtenidos, se pueden plantear varias recomendaciones orientadas tanto a la gestión deportiva como al análisis táctico.

En primer lugar, el **modelo de regresión lineal** aplicado a los puntos por temporada muestra una capacidad limitada para generalizar, con un R^2 moderado y signos claros de sobreajuste entre entrenamiento y test. Esto sugiere que, en un entorno real, no debería utilizarse como única herramienta de planificación de objetivos, sino como apoyo complementario junto con el conocimiento del staff técnico, la situación de mercado y factores contextuales (lesiones, calendario, etc.).

Por otro lado, el modelo de **regresión logística** para predecir Over/Under 2.5 goles ofrece un **rendimiento muy sólido**, con métricas de evaluación casi perfectas y una gran capacidad discriminativa entre ambas clases. En un club, este tipo de modelo podría utilizarse para preparar el plan de partido: si la probabilidad de un encuentro con más de 2.5 goles es alta, el cuerpo técnico podría plantear estrategias más agresivas (presión alta, volumen de tiro elevado, foco en transición ofensiva), mientras que en escenarios con alta probabilidad de Under tendría sentido priorizar estructuras defensivas sólidas y gestión del ritmo de juego.

Desde una perspectiva de negocio y datos, los resultados apuntan a la **necesidad de ampliar el dataset con más temporadas y variables** contextuales para mejorar la robustez del modelo de puntos por temporada (regresión lineal) y evitar sobreajuste.

Ilustración 1- Distribución de valores nulos 4
Ilustración 2 - Dataset limpio 4
Ilustración 3 - Top 10 outliers 5
Ilustración 4 - Matriz de correlación 5
Ilustración 5 - Regresión Lineal 6
Ilustración 6 - Evaluación Regresión Lineal 7
Ilustración 7 - CV Regresión lineal 7
Ilustración 8 - CV Regresión lineal media 8
Ilustración 9 - Regresión logística objetivo 8
Ilustración 10 - Regresión logística 9
Ilustración 11 - Evaluación Regresión Logística 9
Ilustración 12 - Evaluación Random Forest 10